

基于 Python 爬虫的 58 同城招聘信息采集与数据清洗实践

一、 问题背景

当前，高校大学生在职业规划过程中往往面临就业信息碎片化与不对称的困境，例如：对就业市场真实的岗位需求、薪资水平及任职能力标准缺乏系统认知以及就业信息渠道零散，难以高效整合。不少临近毕业的学生往往到求职阶段才发现个人能力与岗位要求之间存在明显差距，导致求职准备被动而盲目。为了帮助学生合理规划学习与实习方向，有针对性地补齐能力短板，此次借助爬虫技术采集主流招聘平台的岗位数据，基于真实信息形成客观的就业参考，通过量化分析企业用人标准，选取 58 同城（武汉）IT 类岗位作为采集对象。采用此对象主要基于以下三点考量：第一，平台岗位覆盖面广，涉及软件开发、数据分析、运维等多种方向；第二，页面融合了静态 HTML 元素与动态渲染内容，便于开展多样化的数据抓取实践；第三，岗位信息包含岗位名称、学历要求、薪资等结构化字段，可支撑后续的数据统计与分析，同时整体实操难度适中，具有良好的实践价值。

二、 爬虫目标与 python 库

1. 目标 URL: <https://wh.58.com/>

2. 采集字段

字段名	说明	示例
工作地点/岗位名称	xx 区/招聘职位标题	光谷/Java 开发工程师
公司名称	企业名称	湖北慧辰信息
薪资	薪酬范围（清洗后）	15k-25k
学历要求	最低学历	大专
详情链接	岗位详情页 URL	https://...

3. 所用到的 python 库及功能介绍

requests: 获取并解析目标网站的 Robots 协议，确认允许爬取的路径。

selenium: 驱动 Chrome 浏览器，模拟真实用户操作，如滚动、翻页等，解决动态内容

渲染问题。

BeautifulSoup4: 解析网页源码, 利用 CSS 选择器精准抽取岗位条目中的字段。


csv: 内置模块, 用于将字典列表写入 CSV 文件, 并指定 UTF-8 编码。

re: 对薪资等半结构化文本进行标准化清洗, 如“8千-1.2万”转换为“8k-12k”。

time: 控制请求间隔, 降低反爬风险。

三、爬虫架构设计

1. 流程图所示



2. 文字描述

程序启动后, 先检查 Robots 协议, 确认允许爬取。接着初始化关键词与页数等参数, 启动 Chrome 浏览器打开 58 同城武汉首页, 等待用户手动登录后按回车跳转搜索页。进入分页循环: 每页通过 Selenium 加载, 显式等待列表容器出现, 模拟滚动触发懒加载。获取页面源码后, BeautifulSoup 解析提取岗位名称、公司、薪资、学历、地点和链接; 薪资经正则清洗统一为“Xk-Yk”格式, 学历缺失则填“不限”, 并将地点与岗位合并。数据逐页汇总, 全部分页完成后按地点+岗位+公司去重, 最终保存为 CSV 文件, 控制台输出采集总量与去重后条数, 关闭浏览器结束。

四、爬虫子模块实现

1. 环境配置与初始化模块

```
import csv

import time

import re

from selenium import webdriver

from selenium.webdriver.common.by import By
```

```

from selenium.webdriver.support.ui import WebDriverWait

from selenium.webdriver.support import expected_conditions as EC

from selenium.webdriver.chrome.options import Options

from selenium.webdriver.chrome.service import Service

from bs4 import BeautifulSoup

KEYWORD = "it"

CITY_URL = "https://wh.58.com/"

PAGES = 3

OUTPUT_FILE = "58job_it.csv"

DRIVER_PATH = "./chromedriver"

SEARCH_URL_TEMPLATE = (
    "https://wh.58.com/job/"
    "?key=it"
    "&final=1&jump=1&page={}"
)

```

2. 数据清洗模块

```

def clean_salary(salary_text):
    if not salary_text:
        return ""

    salary_text = salary_text.strip()

    if "面议" in salary_text or salary_text == "":
        return "面议"

    nums = re.findall(r"[\d.]+", salary_text)

    if len(nums) >= 2:
        low = round(float(nums[0]))
        high = round(float(nums[1]))

        if "万" in salary_text:
            low = int(low * 10)
            high = int(high * 10)

        return f"{low}k-{high}k"

```

```

elif len(nums) == 1:

    val = round(float(nums[0]))

    if "万" in salary_text:

        val = int(val * 10)

    return f"{val}k"

else:

    return salary_text

def clean_education(edu_text):

    return edu_text.strip() if edu_text and edu_text.strip() else "不限"

```

3. 浏览器控制与主流程模块

```

def main():

    chrome_options = Options()

    service = Service(executable_path=DRIVER_PATH)

    driver = webdriver.Chrome(service=service, options=chrome_options)

    driver.maximize_window()

    try:

        print("正在打开 58 同城武汉首页...")

        driver.get(CITY_URL)

        input(">>> 请在浏览器中完成登录（如扫码/账号），登录成功后按回车键继续...")

        print(f"正在跳转到 “{KEYWORD.upper()}” 岗位搜索页...")

        search_url = SEARCH_URL_TEMPLATE.format(1)

        driver.get(search_url)

        time.sleep(3)

        all_jobs = []

```

4. 页面抓取与字段抽取模块

```

for page in range(1, PAGES + 1):

    print(f"正在爬取第 {page} 页...")

    if page > 1:

        url = SEARCH_URL_TEMPLATE.format(page)

        driver.get(url)

```

```

        time.sleep(3)

    try:
        WebDriverWait(driver, 10).until(
            EC.presence_of_element_located((By.CSS_SELECTOR, "li.job_item"))
        )

    except Exception as e:
        print(f'第 {page} 页加载超时或未找到岗位列表, 跳过。错误: {e}')
        continue

    for _ in range(3):
        driver.execute_script("window.scrollTo(0, document.body.scrollHeight);")
        time.sleep(1.5)

    soup = BeautifulSoup(driver.page_source, "lxml")
    job_items = soup.select("li.job_item")
    page_data = []

    for item in job_items:
        title_el = item.select_one(".job_name")
        title = title_el.text.strip() if title_el else ""
        comp_el = item.select_one(".comp_name")
        company = comp_el.text.strip() if comp_el else ""
        salary_el = item.select_one(".job_salary")
        salary = clean_salary(salary_el.text) if salary_el else ""
        edu_el = item.select_one(".job_edu")
        education = clean_education(edu_el.text) if edu_el else "不限"
        area_el = item.select_one(".job_area")
        area = area_el.text.strip() if area_el else ""
        link_el = item.select_one("a")
        link = link_el.get("href") if link_el else ""
        location_job = f"{area}/{title}" if area else title
        page_data.append({
            "工作地点/工作岗位": location_job,

```

```

        "公司名称": company,
        "薪资": salary,
        "学历要求": education,
        "详情链接": link
    })

    print(f"  本页提取到 {len(page_data)} 条岗位")
    all_jobs.extend(page_data)
    time.sleep(2)

```

5. 去重与 CSV 存储模块

```

seen = set()

unique_jobs = []

for job in all_jobs:
    key = (job["工作地点/工作岗位"], job["公司名称"])

    if key not in seen:
        seen.add(key)

        unique_jobs.append(job)

field_names = ["工作地点/工作岗位", "公司名称", "薪资", "学历要求", "详情链接"]

with open(OUTPUT_FILE, "w", encoding="utf-8-sig", newline="") as f:
    writer = csv.DictWriter(f, fieldnames=field_names)
    writer.writeheader()
    writer.writerows(unique_jobs)

print(f"\n  爬取完成！共获取 {len(all_jobs)} 条原始数据，去重后保留
{len(unique_jobs)} 条。")

print(f"结果已保存至：{OUTPUT_FILE}")

except Exception as e:
    print(f"程序出现异常：{e}")


finally:
    driver.quit()

if __name__ == "__main__":
    main()

```

五、 结论与展望

1. 运行截图



2. 爬取数据展示

工作地点/工作岗位	公司名称	薪资	学历要求	详情链接
青山区 it技术支持: 软件服务工	武汉华添翼能源环境科技有限公司	10000k-10500k	不限	https://wh.58.com/tech/66485501576090x.shtml?psid=151
蔡甸区 网红汽配厂/普工6500	湖北仟里马时代人力资源有限公司	6000k-7000k	不限	https://wh.58.com/zpshengchankaifa/66131818035620x.shtml?psid=151
广埠屯 【广埠屯】4K计算机助理包住	武汉千米家维科技有限公司	3500k-6000k	不限	https://wh.58.com/tech/57373221868450x.shtml?psid=151
团结大道 【团结大道】多媒体设备安装及...	湖北腾旭鸿宇科技有限公司	面议	不限	https://wh.58.com/tech/65932402652476x.shtml?psid=151
光谷 it技术支持包住3千5-6千	武汉千米家维科技有限公司	3500k-6000k	不限	https://wh.58.com/tech/57373177175821x.shtml?psid=151
团结大道 技术专员包住交通补助餐补	湖北腾旭鸿宇科技有限公司	面议	不限	https://wh.58.com/tech/65537901365563x.shtml?psid=151
蔡甸区 蔡甸电脑带薪学徒包吃	武汉鑫众潮科技有限公司	3000k-6000k	不限	https://wh.58.com/tech/53161112454796x.shtml?psid=151
蔡甸区 技术专员/附近优先: 月可入5千	武汉鑫众潮科技有限公司	3000k-5000k	不限	https://wh.58.com/tech/44705444631836x.shtml?psid=151
蔡甸区 技术支持能月入5千	武汉鑫众潮科技有限公司	3000k-5000k	不限	https://wh.58.com/tech/50288650829352x.shtml?psid=151
蔡甸区 技术专员/助理 (附近优先)	武汉鑫众潮科技有限公司	3000k-5000k	不限	https://wh.58.com/tech/42160263282456x.shtml?psid=151
蔡甸区 技术支持/维护 (附近优先)	武汉鑫众潮科技有限公司	3000k-6000k	不限	https://wh.58.com/tech/45320044420018x.shtml?psid=151
蔡甸区 技术维护师傅7000 (附近优先)	武汉鑫众潮科技有限公司	3800k-7600k	不限	https://wh.58.com/tech/42115708710298x.shtml?psid=151
蔡甸区 电脑维修员 (附近优先)	武汉鑫众潮科技有限公司	3000k-5000k	不限	https://wh.58.com/tech/20789097386753x.shtml?psid=151
广埠屯 it技术支持/五险: 月可入5千	武汉邦圣伟业科技有限公司	3500k-6000k	不限	https://wh.58.com/tech/65611415371917x.shtml?psid=151

3. 解释

本项目以 58 同城武汉地区 IT 类动态招聘页面为数据获取对象，整合运用 Selenium 自动化测试工具、BeautifulSoup 网页解析库与正则表达式匹配技术，搭建了一套完整的网页数

据爬取与数据清洗流程，高效完成了招聘网页动态数据的批量采集、筛选、纠错与标准化处理工作。针对 58 同城招聘页面存在的动态加载、反爬验证复杂、页面数据碎片化等痛点，项目采用“手动登录+自动翻页”的创新组合设计方案，有效规避了平台高难度的人机验证、滑块验证等模拟登录风控限制，既大幅降低了爬虫被拦截、封禁的概率，又保障了多页面、多批次招聘数据的全面采集，避免了数据遗漏、缺失等问题，最大限度保证了数据源的完整性与真实性。在数据处理环节，项目通过规范化的清洗逻辑剔除无效空白数据、重复招聘信息、残缺字段及干扰字符，统一标准化各类岗位信息的字段格式，最终输出结构清晰、字段规整、维度统一的 CSV 格式数据集。该数据集兼容性极强，可直接导入 Pandas 数据分析工具开展数据筛选、统计建模、特征分析等深度数据挖掘工作，也可支撑各类数据可视化工具完成岗位薪资、工作地点、任职要求、岗位类型等维度的图表绘制，能够客观、真实地还原当前武汉 IT 行业招聘岗位的分布特征、薪资水平及市场需求现状。本次项目实践，充分验证了以 Selenium 结合解析、匹配技术搭建的爬虫方案，在就业信息批量聚合、行业数据采集分析场景中的高度可行性与高效性，为区域性就业市场数据调研、行业招聘趋势分析提供了高效、可靠的技术实现思路。

4. 展望

在当前系统版本中，整体功能虽已实现基础的招聘信息爬取与整理，但在实用性、稳定性与拓展性上依旧存在不少优化提升的空间。后续可进一步完善自动化反爬对抗机制，有效规避站点访问限制，大幅提升数据爬取过程的稳定性与连续性；同时拓展数据抓取字段，跳转至岗位详情页深度采集岗位职责、公司规模、任职要求等更多维度信息，进一步扩充并完善数据集内容。还可搭配 MySQL 数据库，搭建起自动化定时采集、持久化存储的运行体系，打造能够实时迭代、持续更新的就业信息资源库。在此基础上依托已采集的海量数据开展可视化分析，制作岗位分布热力图、薪资区间分布图等直观图表，让数据价值落地，为就业选择提供可靠参考。长远来看，本项目还可进一步迭代升级为专属校园就业服务工具，助力在校学生实时了解行业招聘行情与市场动态，推动求职模式从传统的被动浏览信息，逐步转向以数据为支撑的科学化职业规划。